

But du projet: Prédiction de classement des langages les plus populaires sur Github parmi les repos publics

Quelles données en entrée et en sortie du pipeline.

in: Données publiques de la plateforme GitHub. (endpoint /search/repositories depuis API Resquest Github)

out: Langage le plus utilisé voire classement selon top

- **mongo express:** Visualisation des données mongoDB

- **mongoDB:** Base de données non formaté

data: repositories public au format json

- **api base mongo:** API d'accès à la base mongoDB

call_mode: endpoint

in: data de repositories

out: données venant de la base

- **api request github:** composant appelant l'API github pour récupérer les données des repositories publics

call_mode: endpoint

in: repositories json from Github

out: repositories github nettoyés et formatés

- **Kafka:** Distribue les données entre les composants du pipeline sans dépendre de leur fonctionnement.

- **MLFlow:** Gère l'entrainement et le déploiement des modèles

- **train model:** Script d'entrainement des modeles

in: repositories from api-base-mongo

out: classification model trained

- **model serving:** mise à disposition du modèle choisi

in: date de la création de repositories

out: prédiction du langage

Challenge et perspective :

- Challenge :
 - Prise en main d'Azure, MLFlow
 - Implémenter kafka
- Perspective :
 - Déployer tout le pipeline sur azure
 - Github Actions dynamique
 - Déploiement de modèle de façon agnostique

